

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
”ВЫСШАЯ ШКОЛА ЭКОНОМИКИ”»

Московский институт электроники и математики

Юткин Дмитрий Игоревич, группа БИВ-144
Вдовкин Василий Алексеевич, группа БИВ-144

**Классификация и агрегация новостных статей, используя методы и модели
обработки естественного языка**

Междисциплинарная курсовая работа
по направлению 09.03.01 Информатика и вычислительная техника
студентов образовательной программы бакалавриата
«Информатика и вычислительная техника»

Студент _____ Д.И. Юткин
Студент _____ В.А. Вдовкин

Руководитель
старший преподаватель
Л.Л. Волкова

Москва 2017 г.

Аннотация

В данной курсовой работе изучаются подходы к сбору, анализу, классификации и кластеризации текстовых данных. В результате работы удалось собрать корпус новостей, состоящий более чем из 1 млн документов, применить два подхода к классификации текстовых документов: линейный SVM и градиентный бустинг над деревьями, а также KMeans и графовые алгоритмы к кластеризации новостей. Для демонстрации практической значимости исследуемых алгоритмов, был разработан веб-сервис, который в реальном времени агрегирует новости от различных СМИ, автоматически расставляет для них теги и объединяет в кластеры семантически близкие статьи.

Abstract

The coursework is dedicated to research of mining, analysis, classification and clustering methods of text data. As a result, a dataset with more than 1 million Russian news articles was collected. Two approaches for text classification were successfully applied: linear SVM and gradient boosted trees. For solving clustering problem KMeans and graph-based algorithms were utilized. In order to show a practical appliance of the research methods, web-service was developed. The web-service is able to aggregate and analyze text data in the real-time. Moreover, it automatically labels news articles and cluster them by semantic similarity.

Оглавление

| | |
|---|-----------|
| 1 Введение | 4 |
| 2 Цель и задачи курсовой работы | 5 |
| 3 Сбор и подготовка данных | 5 |
| 3.1 Получение данных из новостных источников | 5 |
| 3.2 Нормализация новостных статей | 6 |
| 4 Классификация новостных статей | 8 |
| 4.1 Линейная модель на TF-IDF признаках | 8 |
| 4.2 Градиентный бустинг над решающими деревьями. Word2Vec и тематическое моделирование. | 11 |
| 5 Кластеризация новостных статей | 14 |
| 5.1 Кластеризация с помощью KMeans | 15 |
| 5.2 Графовый метод кластеризации | 16 |
| 6 Разработка веб-приложения | 17 |
| 7 Заключение | 20 |
| Список литературы | 22 |
| Приложение | 25 |

1 Введение

С каждым годом вычислительные мощности современных компьютеров и сервисов, предлагающие облачные вычисления, позволяют обрабатывать всё большие массивы данных. Благодаря этому происходит быстрое развитие алгоритмов анализа данных и машинного обучения. Результат работы этих алгоритмов можно увидеть в нашей повседневной жизни: сервисы прогноза погоды, которые предсказывают направление движения облаков, персонализированная реклама, подстраивающиеся под интересы пользователя, автомобили с автопилотом и т.д. — в основе всех этих разработок лежат алгоритмы интеллектуального анализа данных и машинного обучения.

Одна из важнейших проблем, возникающая перед исследователями и разработчиками подобных систем, заключается в поиске данных для обучения моделей, которые в будущем будут использоваться для анализа новой информации.

Решением данной проблемы являются тексты из сети Интернет. Петабайты информации, записанной на естественном языке за последние несколько десятилетий, доступны любому исследователю. Книги, новостные статьи, блоги, посты в социальных сетях — всё это является источником легкодоступных данных.

Именно поэтому обработка естественного языка (Natural Language Processing, NLP) получила большое развитие. За последние несколько лет появилось множество специализированных библиотек и сервисов для анализа естественного языка. К таким сервисам, например, относится IBM Watson — набор платных продуктов, предлагающий различные инструменты работы с текстом: от извлечения важной информации и классификации, до его генерации. Яркими примерами свободнораспространяемых библиотек являются: NLTK, Gensim, MyStem, rumorphy и многие другие.

В данной работе решаются две задачи:

1. классификация тем новостных статей;
2. кластеризация новостных статей по семантической близости.

Для придания работе новизны и оригинальности задача решается для русскоязычных новостей.

Практическая значимость работы доказывается на примере реализации в виде веб-сервиса новостного агрегатора, который в реальном времени, с помощью

алгоритмов и подходов предложенных в данной работе, обрабатывает публикации русскоязычных интернет-СМИ.

2 Цель и задачи курсовой работы

Целью курсового проекта является разработка веб-сервиса для агрегации, классификации и кластеризации новостных статей на русском языке, с использованием методов и моделей машинного обучения.

Для достижения поставленной цели, должны быть выполнены следующие задачи:

1. изучить методы автоматической обработки текста и естественного языка;
2. собрать корпус новостных статей для обучения моделей;
3. разработать подсистему автоматической агрегации новостей;
4. разработать подсистему классификации новостей;
5. разработать подсистему кластеризации новостей;
6. произвести оценку качества алгоритмов классификации и кластеризации;
7. разработать back-end и front-end инфраструктуру сервиса;
8. сделать выводы из проведённого исследования;
9. составить отчёт о проделанной работе.

3 Сбор и подготовка данных

3.1 Получение данных из новостных источников

Для получения робастных моделей машинного обучения, требуется достаточно большой корпус новостных статей, содержащий несколько сотен тысяч документов. Обычно существуют готовые коллекции текстов, но из-за выбранных ограничений к документам, а именно: новости на русском языке вместе с тег — словом, описывающим тему документа, найти такой корпус не удалось, поэтому было принято решение собрать данные самостоятельно.

В качестве новостных источников были выбраны следующие популярные СМИ: «Газета.Ru», «Lenta.ru», «ТАСС», «Новая Газета», «ВЕДОМОСТИ», «РИА Новости» и «СПОРТ-ЭКСПРЕСС». Последнее было выбрано по причине малого количества спортивных новостей от других источников.

При анализе сайтов СМИ стало понятно, что они имеют схожую структуру: для отображения ссылок на статьи, используются страницы со списком новостей

(«Лента новостей»), по которым можно итерироваться, изменяя параметры запросов, например, дату последней новости на странице или количество показанных статей. Для извлечения данных из источников реализован набор алгоритмов, которые опираются на описанную структуру.

Стоит отметить, что во многих случаях для получения чистого текста приходится ждать ответа от сервера и обрабатывать HTML содержание страниц, что сильно замедляет работу, поэтому алгоритмы получения новостей одновременно обрабатывают в параллельных процессах множество веб-страниц, что значительно ускоряет работу. Данные алгоритмы также используются в основном веб-сервисе для получения недавних новостей.

При формировании корпуса, все новостные статьи сопровождалась различными метаданными: название СМИ, ссылка на статью, дата публикации, тег и заголовок. В результате было получено более 1,1 млн. новостей с 1999 по 2017 год, многие из которых имели неправильно проставленные темы или не имели тем вовсе. Причин тому может быть несколько, например, ошибки редакторов или технические ограничения веб-сайтов новостных агентств. Например, большинство новостей на сайте «Новой Газеты» помечены тегом «политика», что зачастую не совпадает с истинным содержанием статьи. После детального анализа тегов стало ясно, что относить новости к рубрикам редакторы стали только после определённого времени, а все уже имеющиеся статьи на сайте отнесли в «политику». Некорректные данные пришлось удалить.

В итоговую выборку, которая в дальнейшем использовалась для обучения и тестирования алгоритмов, вошло 133 529 статей, помеченных 32 различными темами. Распределение СМИ и тем на отобранных данных отражено на рисунке 1.

3.2 Нормализация новостных статей

Нормализация является одной из важнейших стадий обработки естественного языка. Не формально, нормализация приводит текст в более информативный для моделей вид. В зависимости от языка процесс нормализации может отличаться. Например, для русского языка зачастую удаляют пунктуацию и стоп-слова, а также производят лемматизацию. Стоп-слова — это слова, которые примерно одинаково распределены по всему корпусу языка, чаще всего ими являются место-




Рисунок 1 — Распределение СМИ и тем в данных

имения, предлоги и союзы. Лемматизация — приведение слова в начальную форму (лемму):

- для существительных — именительный падеж, единственное число;
- для прилагательных — именительный падеж, единственное число, мужской род;
- для глаголов, причастий, деепричастий — глагол в инфинитиве.

Часто вместо лемматизации используется стемминг — алгоритм, который убирает части слова, влияющие на его форму, например, окончание. В результате применения данной процедуры однокоренные слова, как правило, преобразуются к одинаковому виду. Данные алгоритмы не только опираются на словари, но и на определённые правила, зависящие от языка, так как в корпусе могут встречаться слова в разных формах, которых нет в словаре, например, неологизмы, но образованы они по правилам языка.

Процесс обработки текста в данной работе состоит из нескольких последовательных этапов:

1. приведение текста в нижний регистр;
2. удаление чисел и символов пунктуации, дефис сохраняется;
3. удаление стоп-слов. В данный набор входят наиболее часто употребляемые слова русского и английского языков а также названия новостных агентств («лента», «тасс», «риа» и т.д.), сохранение которых приводит к переобучению моделей;
4. лемматизация каждого слова с помощью библиотеки MyStem [1].

4 Классификация новостных статей

За последние два десятка лет, в результате активных исследований в области машинного обучения, было изобретено множество успешных алгоритмов классификации. Например, такие модели как support vector machines (SVM) [2], градиентный бустинг над решающими деревьями и нейронные сети [3], были успешно применены к задачам классификации текстов. В данной работе для классификации новостных статей использовались две из перечисленных выше модели — это SVM и градиентный бустинг над решающими деревьями.

Анализ текста является важной частью машинного обучения, однако сырые данные, а именно последовательности символов переменной длины, не могут быть переданы на вход алгоритму в явном виде т.к. большинство моделей ожидают численный вектор признаков фиксированной длины.

Векторизация — метод трансформации коллекции текстовых документов в числовые вектора признаков. Существуют различные подходы к векторизации текста, в данной работе были применены два самых популярных: TF-IDF и word2vec.

4.1 Линейная модель на TF-IDF признаках

Одним из самых простых подходов к решению задачи классификации текстовых документов является обучение линейного классификатора на TF-IDF признаках, посчитанных на корпусе документов.

TF-IDF [4] — статистическая мера, используемая для оценки важности слова в контексте документа, являющегося частью коллекции документов или корпуса. TF-IDF — это произведение двух статистик: TF (term frequency) и IDF (inverse document frequency). На сегодняшний день, TF-IDF один из самых популярных способов взвешивания слов, входящих в корпус документов. Например, 83% рекомендательных систем цифровых библиотек используют TF-IDF [5].

Существует множество способов подсчёта TF-IDF, в данной работе использовался следующий:

$$\text{tf}(t, d) = \frac{n_t}{\sum_k n_k},$$

где n_t есть число вхождений слова t в документ, а $\sum_k n_k$ — общее число слов в данном документе.

$$\text{idf}(t, D) = \log \frac{|D|}{|\{d_i \in D \mid t \in d_i\}|},$$

где $|D|$ — число документов в корпусе, $|\{d_i \in D \mid t \in d_i\}|$ — число документов из коллекции D , в которых встречается t (когда $n_t \neq 0$).

Таким образом, мера TF-IDF является произведением двух сомножителей:

$$\text{TF-IDF}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D).$$

Признаковым описанием одного объекта $d \in D$ будет вектор

$$(\text{TF-IDF}(t, d, D))_{t \in V},$$

где V — словарь всех слов, встречающихся в коллекции D .

Для преобразования новостных статей в числовые признаки, использовался класс `TfidfVectorizer` из библиотеки машинного обучения `Scikit-learn` [6]. В качестве параметров векторизации использовались следующие значения: `min_df=3` — учитываются слова, встретившиеся суммарно во всех документах минимум 3 раза и `ngram_range=(1, 2)` — учитываются как отдельные слова, так и би-граммы.

После векторизации новостных статей, была получена разрежённая матрица размера 133 529 строк на 1 025 919 столбцов. По причине большого количества признаков (\gg обучающих примеров), в качестве классификатора было решено использовать линейный SVM. Не смотря на то, что данный алгоритм был впервые описан более пятидесяти лет назад, сегодня он по прежнему показывает одни из самых высоких результатов в задачах классификации текста. Как было показано в [7], особенно высокое качество удаётся получить при использовании би-грамм.

В данной работе в качестве SVM использовался `SGDClassifier` из библиотеки `Scikit-learn`. Данный класс реализует различные линейные классификаторы, параметры которых оптимизируются с помощью алгоритма стохастического градиентного спуска [8].

Классификатор обучался со следующими параметрами: `loss="hinge"` — функционал качества линейного SVM, `n_iter=70` — число итераций оптимизационного алгоритма, `alpha=1e-5` — коэффициент регуляризации.

Обучение классификатора происходило на 70% новостных статей, остальные 30% использовались для валидации. Процесс разделения выборки был стратифицированным¹, в качестве стратов выступали темы новостей.

Качество классификации оценивалось с помощью метрик Accuracy и F1-меры с макро-усреднением по каждому классу. На валидационном множестве линейному SVM удалось получить Accuracy = 0,8792 и F1 score = 0,8860.

Из матрицы ошибок, приведённой на рисунке 4, можно увидеть, что модель часто ошибается в классификации новостей на тему «экономика», относя их к новостям про «бизнес» (в 20% случаев). Такая же ситуация характерна и для классов «компаний» – «бизнес» (12%), «силовые структуры» – «оружие» (12%), «социальные сети» – «интернет» (15%), «театр» – «кино» (9%). Перечисленные ошибки являются, в основном, причиной семантической схожести классов, но зачастую одна и та же новость может содержать различные темы, поэтому, возможно, нужно было решать данную задачу методами multilabel классификации, т.е. когда один объект может принадлежать сразу нескольким классам.

Напротив, среди всех тем выделяются несколько, которые классифицируются с высокой долей точности. Данные темы являются узкоспециализированными и почти не имеют пересечения с другими. В основном это виды спорта, такие как «футбол» (точность 0,99), «хоккей» (0,99), «формула-1» (1,00), «кибер-спорт» (0,98) и т.д. Более детальные значения метрик по каждому из классов можно найти на рисунке 5а.

Веса признаков в линейной модели в случае, если признаки отмасштабированы, характеризуют степень их влияния на значение целевой переменной. В задаче классификации текстов, кроме того, признаки являются хорошо интерпретируемыми, поскольку каждый из них соответствует конкретному слову, поэтому из линейного SVM были извлечены слова с наибольшим весом для каждой из 32 тем (таблица 2).

¹Стратифицированная выборка — выборка, в которой генеральная совокупность разделена на частичные совокупности, которые сами по себе должны быть однородными, а между собой — разнородными (Финансовый словарь).

4.2 Градиентный бустинг над решающими деревьями. Word2Vec и тематическое моделирование.

Другим популярным подходом к векторизации текста является алгоритм Word2Vec. Реализация алгоритма, опубликованная компанией Google [9] в 2013 году, основывается на однослойной нейронной сети, которая пытается «выучить» векторные представления слов (англ. word embeddings). До этого также были предложены различные архитектуры рекуррентных нейронных сетей, которые могли «выучивать» векторные представления, но их проблема заключалась в том, что они требовали намного больше времени для обучения, в отличие от реализации Word2Vec от Google.

Алгоритм Word2Vec является подмножеством более широкого класса алгоритмов, которые называются Vector space models (VSMs) [10]. VSMs представляют слова в непрерывном векторном пространстве, где семантически похожие слова отображаются в близкие точки. VSMs имеют долгую и богатую историю в NLP, но все представители этого семейства моделей опираются на дистрибутивную семантику, которая утверждает, что слова появляющиеся в одном и том же контексте имеют близкое семантическое значение. Все методы, основанные на данной гипотезе, можно разделить на два класса: статистические, или численные (от англ. count-based, пр. Latent Semantic Analysis) и предиктивные модели (пр. neural probabilistic language models).

Первый класс алгоритмов вычисляет как часто слова возникают в контексте своих соседей в больших корпусах текстов. Затем происходит отображение вычисленных статистик в вектора для каждого слова. В свою очередь, предиктивные модели напрямую пытаются предсказать слова по его контексту, «выучивая» вектора таким образом, чтобы снизить ошибку предсказаний.

В частности, Word2Vec является вычислительно-эффективной реализацией предиктивной модели, которая «выучивает» векторные представления слов из необработанных текстовых данных. Есть две вариации алгоритма: Continuous Bag-of-Words (CBOW) и Skip-Gram. Алгоритмически они похожи, за исключением того, что CBOW предсказывает слово (например «раму») основываясь на контексте («мама мыла»), в то время как Skip-Gram наоборот, старается предсказать контекст по исходному слову. На практике CBOW лучше работает на небольших

корпусах текстов, однако если корпус достаточно большой, как в данной работе, то рекомендуется использовать модель, основанную на Skip-Gram.

В данной работе, для обучения модели Word2Vec использовалась библиотека Gensim [11], в которой имеется обёртка над Word2Vec от Google для языка Python. Модель обучалась со следующими параметрами: `min_count=3` — в обучении используются только те слова, которые встречаются во всём корпусе не менее трёх раз, `vec_size=300` — размерность векторов слов, `window=5` — размер окна (контекста), `sg=1` — использовать алгоритм Skip-Gram, `iter=10` — количество итераций по коллекции документов.

Результатом обучения Word2Vec является словарь, который отображает слова в вектора. Для представления новостной статьи в виде вектора признаков усредним все векторы слов в данной статье с `idf` весами. В результате получим матрицу, в которой 133 529 строк и 300 столбцов (признаков), что значительно меньше, чем в случае TF-IDF. Благодаря тому, что удалось снизить размерность с 1 025 919 признаков до 300, становится возможным эффективное использование таких мощных алгоритмов как градиентный бустинг над решающими деревьями.

Градиентный бустинг над решающими деревьями — один из самых универсальных и сильных методов машинного обучения, известных на сегодняшний день. В последнее время этот алгоритм и, особенно его реализация в библиотеке XGBoost [12], пользуются большой популярностью у участников соревнований в области анализа данных на платформе Kaggle.

В данной работе использовалась реализация градиентного бустинга из библиотеки LightGBM, которая является open-source проектом компании Microsoft. Алгоритм построения деревьев в LightGBM немного отличается от того, как это реализовано в XGBoost. Несмотря на это интерфейс библиотек и параметры алгоритмов зачастую полностью совпадают. Однако на практике LightGBM превосходит в скорости работы XGBoost, именно по этой причине эта библиотека использовалась для решения задачи классификации.

Модель градиентного бустинга над деревьями обучалась на векторах, полученных с помощью Word2Vec, со следующими параметрами:

- `colsample_bytree=0.9` — доля от общего числа признаков, используемая для построения дерева на каждой итерации;
- `learning_rate=0.1` — шаг градиентного спуска, темп обучения;

- `max_depth=7` — ограничение на максимальную глубину дерева;
- `num_leaves=255` — ограничение на максимальное число листьев в дереве;
- `objective="multiclass"` — функционал качества;
- `metric="multi_error"` — метрика, по которой оценивается качество и происходит ранняя остановка;
- `subsample=0.8` — доля от общего числа объектов, используемых для построения дерева на каждой итерации.

Итоговое качество алгоритма: Accuracy = 0,8427, F1 score = 0,8486.

Как видно из результатов, качество градиентного бустинга оказалось ниже линейного SVM, что, возможно, является причиной усреднения слов в документе, во время которого теряется достаточно много информации. Одним из решений данной проблемы является генерация новых признаков. Для этого в работе было применено тематическое моделирование.

Тематическое моделирование — активно развивающаяся ветвь статистического анализа текстов [13]. Тематические модели стараются раскрыть скрытую тематическую структуру коллекции документов и найти сжатое представление каждого документа в виде тем, которые в нём встречаются. Тематическое моделирование применяется в различных задачах, например, таких как информационный поиск, классификация, кластеризация, сжатие текста без потери информации (summarization) и т.д. Различные способы и идеи применения тематических моделей описаны в обзоре [14].

Статистически, модель вероятностного тематического моделирования определяет каждую тему как многомерное распределение над словами $p(w | t)$, где w — слово, t — тема, и затем описывает каждый документ в виде многомерного распределения тем $p(t | d)$, где d — документ. Вероятностная тематическая модель выявляет скрытые темы по наблюдаемым распределениям слов в документах:

$$p(w | d) = \sum_{t \in T} p(w | d, t) p(t | d) = \sum_{t \in T} p(w | t) p(t | d).$$

В данной работе для тематического моделирования использовалась библиотека bigARTM [15] — открытая библиотека для тематического моделирования текстовых коллекций, реализующая алгоритм аддитивной регуляризации тематических

моделей (ARTM). Модель обучалась на коллекции новостных статей со следующими параметрами:

- num_topics=150 — количество тем, которые пытается выделить модель;
- tau=-0.2 — параметр SmoothSparsePhiRegularizer;
- tau=3e5 — параметр DecorrelatorPhi;
- tau=-0.001 — параметр SmoothSparseThetaRegularizer;
- num_collection_passes=50 — число итераций оптимизационного алгоритма;

С помощью обученной модели были получены распределения тем для каждой новостной статьи. Примеры распределений представлены в таблице 1. После чего, полученные векторы распределений были сканкатенированы с векторами из Word2Vec, что в итоге увеличило число признаков с 300 до 450.

| | | | | | | | |
|-----------|--------------|--------------|---------------|--------------|-----------|-----------------|-------------|
| topic_0 | ученый | исследование | журнал | вывод | анализ | исследователь | изучать |
| topic_10 | сделка | доля | принадлежать | актив | покупка | продавать | приобретать |
| topic_103 | пользователь | сервис | google | facebook | яндекс | поиск | запрос |
| topic_105 | сериал | актер | зритель | герой | шоу | сердце | эпизод |
| topic_16 | нефть | добыча | месторождение | нефтяной | запас | баррель | лукойл |
| topic_160 | сша | американский | штат | обама | вашингтон | белый | барак |
| topic_3 | китай | китайский | граница | пространство | опасный | кнр | пекин |
| topic_43 | миллиард | ржд | оцениваться | потратить | сумма | железнодорожный | железный |

Таблица 1: Пример распределений слов в темах, полученных вероятностным тематическим моделированием, с помощью библиотеки bigARTM

Сгенерированные признаки и последующее обучение градиентного бустинга на них, значительно улучшили качество по сравнению с предыдущим результатом (Accuracy = 0,8687, F1 score = 0,8711), однако качество линейного SVM на TF-IDF признаках градиентный бустинг над деревьями превзойти не смог, и именно по этой причине в веб-сервисе для классификации используется SVM. Детальное сравнение качества двух алгоритмов представлено на рисунке 5.

5 Кластеризация новостных статей

Пусть дана выборка $X = (x_i)_{i=1}^{\ell}$, $x_i \in \mathbb{X}$. В задаче кластеризации требуется найти в данных K кластеров — областей, объекты внутри которых похожи друг на друга, а объекты из разных кластеров друг на друга не похожи. Более формально, требуется построить алгоритм $a : \mathbb{X} \rightarrow \{1, \dots, K\}$, определяющий для каждого объекта номер его кластера. Число кластеров K может быть либо известно, либо являться параметром алгоритма.

В данной работе, в качестве меры семантической схожести двух новостей, используется косинусная мера. Пусть есть две новости, которые представлены в виде двух векторов x и y . Известно, что их скалярное произведение и косинус угла α между ними связаны следующим соотношением:

$$\langle x, y \rangle = \|x\| \|y\| \cdot \cos(\alpha).$$

Тогда, косинусное расстояние определяется как

$$\rho_{\cos}(x, y) = \arccos \left(\frac{\langle x, y \rangle}{\|x\| \|y\|} \right).$$

Косинусное расстояние часто используется для измерения схожести между текстами. Каждый документ описывается вектором, каждая компонента которого соответствует слову из словаря. В данной работе, компонента вектора — это TF-IDF вес слова, если оно встречается в тексте, и ноль в противном случае. Тогда косинус между двумя векторами будет тем больше, чем больше общих слов в этих двух документах одновременно.

5.1 Кластеризация с помощью KMeans

В данной работе для кластеризации новостей использовалась модифицированная версия алгоритма KMeans [16]. Данный алгоритм оптимизирует внутрикластерное расстояние, в данной работе это был квадрат евклидовой нормы.

Реализация алгоритма была взята из библиотеки Scikit-learn. `MiniBatchKMeans` — один из способов реализации алгоритма KMeans, в котором используются мини-батчи² для уменьшения времени, затрачиваемое на обучение, при этом оптимизируется тот же самый функционал, что и в оригинальном варианте. Количество кластеров подбиралось так, чтобы число новостей в каждом кластере в среднем было около пяти.

Модификация алгоритма, использующегося в веб-сервисе, отличается от исходного тем, что после того как были выделены центры кластеров, новость добавляется в кластер только если косинусное расстояние между ней и центром кластера больше 0,5.

²Мини-батчи — подмножества входных данных, сэмплируемые случайным образом на каждой итерации обучения.

Кроме того, кластеры упорядочиваются по среднему времени публикации новостей и среднему внутрикластерному расстоянию.

5.2 Графовый метод кластеризации

Данный подход кластеризации основан на алгоритме нахождения связных компонент в графе. Изначально строится полный граф, где вершины — векторное представление новостей, а вес рёбер равен косинусному расстоянию между вершинами. Рёбра, вес которых меньше определённого параметра, игнорируется.

Далее, применяется алгоритм поиска в ширину от первой вершины, не находящейся в кластере. Все вершины, по которым прошёл поиск, добавляются в кластеры и помечаются как посещённые, затем начинается новый поиск от следующей непомяченной вершины. Такой поиск производится до тех пор, пока все вершины не станут находиться в каком-либо кластере.

```

1 threshold  $\leftarrow$  0.5
2 comp  $\leftarrow$  0
3 for  $(u,v) \in E$  do
4    $w(u,v) \leftarrow \cos(u,v)$ 
5 for  $v \in V$  do
6    $c[v] \leftarrow nil$ 
7 for  $v \in V$  do
8   if  $c[v] = nil$  then
9      $c[v] \leftarrow comp$ 
10     $Q \leftarrow \{v\}$ 
11     $S \leftarrow \emptyset$ 
12    while  $Q \neq \emptyset$  do
13       $u \leftarrow pop(Q)$ 
14       $c[u] \leftarrow comp$   $S \leftarrow S \cup \{v\}$ 
15      for  $n \notin S, (u,n) \in E$  do
16        if  $w(u,n) \geq threshold$  and  $c[n] = nil$  then
17           $Q \leftarrow Q \cup \{n\}$ 
18     $comp \leftarrow comp + 1$ 

```

Рисунок 2 — Псевдокод алгоритма поиска компонент в графе

Псевдокод алгоритма приведён на рисунке 2, где *threshold* — пороговое значение веса рёбер; *comp* — номер текущей компоненты; V — список вершин; E —

список рёбер; v, u, n — вершины; $(u, v), (u, n)$ — рёбра; $w(u, v)$ — вес ребра (u, v) ; $c[v]$ — компонента вершины v ; Q, S — очереди.

Оценка качества кластеризации осуществлялась имперически, т.к. численные метрики, например, такие как внутрикластерное расстояние или индекс Данна [17], в данной задаче слабо коррелировали с тем, на сколько похожими получались новости внутри кластеров.

Из двух рассмотренных методов кластеризации на практике лучше себя показал KMeans, поэтому он был включён в новостной агрегатор в качестве основного алгоритма кластеризации.

6 Разработка веб-приложения

Веб-приложение состоит из двух основных частей: back-end и front-end. Back-end — это сам веб-сервер, который осуществляет обработку запросов пользователей, получение и обработку данных. Front-end — это пользовательский интерфейс, визуализирующий полученные от back-end данные в понятный вид. С помощью этого интерфейса пользователь способен не только получать, но и передавать данные на back-end.

Back-end составляющая сервиса реализована на языке Python 3, с использованием фреймворка Flask — обработка HTTP запросов пользователей, библиотеки Pandas — обработка и хранение данных, Scikit-learn — вычисление TF-IDF, алгоритмы KMeans и линейный SVM, а также rumystem3 для лемматизации слов.

Структура приложения показана на рисунке 3.

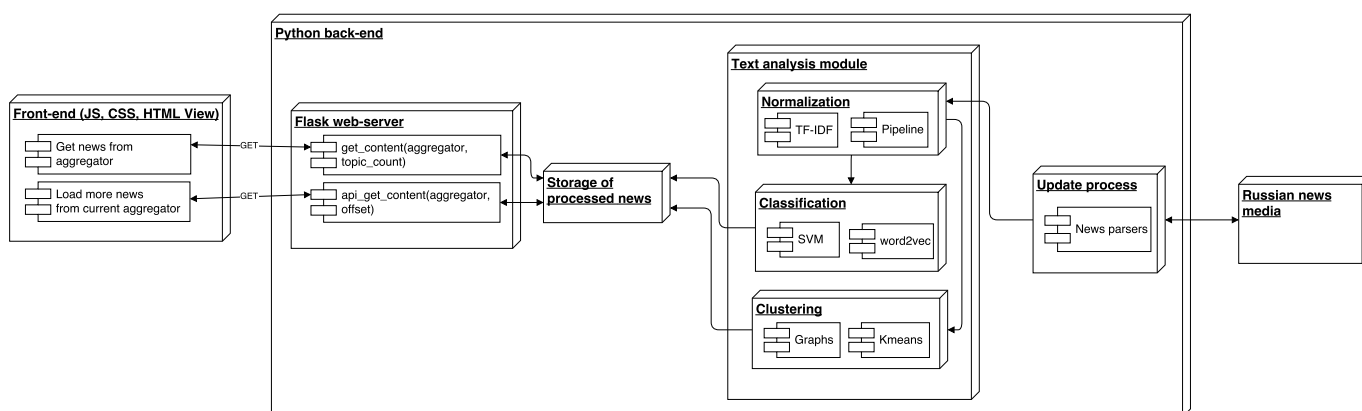


Рисунок 3 — Структура сервера

Back-end разделён на несколько модулей: Flask веб-сервер, модуль парсеров (англ. parser) новостей, которые с помощью параллельных процессов извлекают данные из сайтов СМИ, а также модуль анализа данных.

При запуске сервера происходит получение и обработка новостей за последние 12 часов. После чего запускается отдельный процесс, отвечающий за актуальность данных: каждую минуту он проверяет наличие новых статей, и, если такие есть, получает и отправляет их на обработку. При запросе с Front-end, сервер не обрабатывает данные с нуля, а обращается к уже обработанным, хранящимся в кэше, данным.

Основной частью сервера является класс `Analizer`, обрабатывающий полученные новостные статьи.

Данный класс, имеет следующие методы:

- Конструктор. Параметры: список новостных статей с мета-данными.
В конструкторе класса производится загрузка сохранённых моделей, определяются параметры моделей кластеризации, вызываются функции `_data_to_pandas`, `_classify`, `_classify`, `_aggregate`, `_form_output`.
- `append_data`. Параметры: список новостных статей с мета-данными.
Функция отвечает за добавление новых данных. Вызываются те же методы, что и в конструкторе. Дополнительно удаляются устаревшие данные.
- `_data_to_pandas`. Параметры: список новостных статей с мета-данными. Возвращаемое значение: `Pandas Dataframe`, в котором хранится вся информация об актуальных новостях.
Список новостей конвертируется в таблицу `Pandas Dataframe`, из которой удаляются дубликаты, лишние мета-данные, происходит сортировка по дате публикации статьи. Вызывается функция `_norimalize`.
- `_norimalize`. Параметры: `Pandas Dataframe`.
Происходит вызов конвеера функций нормализации текста. К таблице добавляются нормализованные текст и заголовок статей.
- `_classify`. Параметры: `Pandas Dataframe`.
Вызываются функции классификации. Для каждого классификатора реализована отдельная функция, в которой к таблице добавляются колонка с тегами, полученными от данного классификатора.

- `_aggregate`. Параметры: Pandas Dataframe и конфигурация алгоритмов кластеризации.
Вызываются функции кластеризации: `_aggregate_Kmeans`, `_aggregate_graphs`.
Для каждого алгоритма кластеризации реализована отдельная функция, которая возвращают список кластеров, каждый кластер представляет собой список ID — индекс новости в таблице Pandas Dataframe.
- `_sort_groups`. Параметры: список кластеров, полученный от алгоритмов кластеризации. Возвращает отсортированный список кластеров.
Фильтрует кластеры, в которых меньше двух новостей, после чего сортирует кластеры по среднему времени публикации. Затем происходит сортировка новостей внутри кластеров по времени их публикации.
- `_get_avg_time`. Параметры: кластер. Возвращает среднее время в кластере.
Преобразовывает даты публикации каждой новости кластера в Unix-timestamp и считает от них среднее.
- `_get_TFIDF`. Параметры: Pandas Dataframe. Возвращает модель TF-IDF и матрицу векторизованных новостей.
- `_class_to_str`. Параметры: id класса. Возвращает название класса.
- `_cut_text`. Параметры: текст. Возвращает первый абзац текста.
- `_date_to_str`. Параметры: дата публикации. Возвращает дату в виде строки в заданном формате.
- `_form_output`. Параметры: Pandas Dataframe, список кластеров.
Формирует данные в формате JSON и сохраняет их.
- `get_data`. Параметров нет. Возвращает готовые данные в формате JSON и дату самой актуальной новости.

Front-end (рисунок 6) реализован на HTML, CSS и JS, с использованием библиотеки стилей w3css. В интерфейсе пользователя доступна возможность менять алгоритмы кластеризации. Новости в интерфейсе поделены на темы, для каждой статьи пишется её заголовок, при клике на который можно перейти на сайт СМИ, название СМИ, время публикации, тема новости, предсказанная моделью SVM, и первый параграф текста. Изначально на странице отображаются только первые

пять тем, остальные темы можно подгрузить, нажав на кнопку «Load more» внизу страницы.

7 Заключение

В результате курсовой работы был спроектирован и разработан веб-сервис — новостной агрегатор, который в реальном времени получает новости из русскоязычных источников, автоматически проставляет для них теги и группирует семантически близкие статьи из разных СМИ.

В процессе работы над проектом были изучены методы сбора, анализа, классификации, а также кластеризации текстов на естественном языке.

В связи с отсутствием готового набора данных, удовлетворяющего поставленным требованиям, была собрана в автоматическом режиме коллекция русскоязычных новостных статей с 1999 по 2017 год, насчитывающая более 1 млн. документов. Данный корпус использовался для проведения исследований по классификации и кластеризации русскоязычных текстов.

На практике были применены два способа классификации текстовых документов: с использованием линейного SVM на TF-IDF признаках и градиентный бустинг над деревьями на векторных эмбедингах Word2Vec и признаках, полученных с помощью вероятностной тематической модели ARTM. Было показано, что в данной задаче, более простая линейная модель обладает большей обобщающей способностью по сравнению с градиентным бустингом. Более того, линейный SVM требует намного меньше времени для обучения и предсказания меток классов.

Для кластеризации новостных статей было изучено и применено на практике два алгоритма: KMeans и выделение связанных компонент в графе. Оба алгоритма показали приемлемое качество, но кластеризация с помощью KMeans, чаще выделяла в кластеры более семантически похожие новости, в отличие от алгоритма, основанного на графах, благодаря этому, в финальной версии веб-сервиса данный алгоритм установлен по умолчанию.

В качестве демонстрации практической применимости изучавшихся в данной работе теории и моделей машинного обучения, было разработано веб-приложение³, back-end подсистема которого в реальном времени получает актуальные

³<https://github.com/yutkin/News-Aggregator/>

новости из различных новостных источников, нормализует и векторизует их, автоматически предсказывает для них теги и кластеризует их в семантические кластеры. В свою очередь, front-end подсистема, представляющая из себя веб-страницу, показывает пользователю сгруппированные новости и общий заголовок для них.

Таким образом, все поставленные в курсовой работе задачи выполнены, цель работы достигнута. По результатам проделанной работы сформирован отчёт.

Список литературы

1. *Ilya Segalovich*. A fast morphological algorithm with unknown wordguessing induced by a dictionary for a web search engine // *In Proc. of MLMTA-2003. Las Vegas*. — 2003. <https://download.yandex.ru/company/iseg-las-vegas.pdf>.
2. *Weston Jason, Watkins Chris*. Support Vector Machines for Multi-class Pattern Recognition // *Proc. European Symposium on Artificial Neural Networks*. — 1999. — Pp. 219–224.
3. Very Deep Convolutional Networks for Natural Language Processing / *Alexis Conneau, Holger Schwenk, Loïc Barrault, Yann LeCun* // *CoRR*. — 2016. — Vol. abs/1606.01781. <http://arxiv.org/abs/1606.01781>.
4. *Jones Karen Sparck*. A statistical interpretation of term specificity and its application in retrieval // *Journal of Documentation*. — 1972. — Vol. 28, no. 1. — Pp. 11–21. <http://dx.doi.org/10.1108/eb026526>.
5. Research-paper recommender systems: a literature survey / *Joeran Beel, Bela Gipp, Stefan Langer, Corinna Breiteringer* // *International Journal on Digital Libraries*. — 2016. — Vol. 17, no. 4. — Pp. 305–338. <http://dx.doi.org/10.1007/s00799-015-0156-0>.
6. Scikit-learn: Machine Learning in Python / *F. Pedregosa, G. Varoquaux, A. Gramfort et al.* // *Journal of Machine Learning Research*. — 2011. — Vol. 12. — Pp. 2825–2830.
7. *Wang Sida I., Manning Christopher D*. Baselines and Bigrams: Simple, Good Sentiment and Topic Classification // *Proceedings of the ACL*. — 2012. — Pp. 90–94.
8. *Bottou Léon*. Large-Scale Machine Learning with Stochastic Gradient Descent // *Proceedings of COMPSTAT'2010: 19th International Conference on Computational Statistics Paris France, August 22-27, 2010 Keynote, Invited and Contributed Papers* / Ed. by *Yves Lechevallier, Gilbert Saporta*. — Heidelberg: Physica-Verlag HD, 2010. — Pp. 177–186. http://dx.doi.org/10.1007/978-3-7908-2604-3_16.

9. Efficient Estimation of Word Representations in Vector Space / Tomas Mikolov, Kai Chen, Greg Corrado, Jeffrey Dean // *CoRR*. — 2013. — Vol. abs/1301.3781. <http://arxiv.org/abs/1301.3781>.
10. Salton G., Wong A., Yang C. S. A Vector Space Model for Automatic Indexing // *Commun. ACM*. — 1975. — nov. — Vol. 18, no. 11. — Pp. 613–620. <http://doi.acm.org/10.1145/361219.361220>.
11. Řehůřek Radim, Sojka Petr. Software Framework for Topic Modelling with Large Corpora // Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks. — Valletta, Malta: ELRA, 2010. — May. — Pp. 45–50. — <http://is.muni.cz/publication/884893/en>.
12. Chen Tianqi, Guestrin Carlos. XGBoost: A Scalable Tree Boosting System // *CoRR*. — 2016. — Vol. abs/1603.02754. <http://arxiv.org/abs/1603.02754>.
13. Blei David M. Probabilistic Topic Models // *Commun. ACM*. — 2012. — apr. — Vol. 55, no. 4. — Pp. 77–84. <http://doi.acm.org/10.1145/2133806.2133826>.
14. Knowledge discovery through directed probabilistic topic models: a survey / Ali Daud, Juanzi Li, Lizhu Zhou, Faqir Muhammad // *Frontiers of Computer Science in China*. — 2010. — Vol. 4, no. 2. — Pp. 280–301. <http://dx.doi.org/10.1007/s11704-009-0062-y>.
15. Vorontsov K. Frei O. Apishev M. Romov P. Dudarenko M. BigARTM: Open Source Library for Regularized Multimodal Topic Modeling of Large Collections // *Frontiers of Computer Science in China*. <https://s3-eu-west-1.amazonaws.com/artm/Voron15aist.pdf>.
16. MacQueen J. Some methods for classification and analysis of multivariate observations // Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Statistics. — Berkeley, Calif.: University of California Press, 1967. — Pp. 281–297. <http://projecteuclid.org/euclid.bsmsp/1200512992>.

17. *Dunn J.C.* A Fuzzy Relative of the ISODATA Process and Its Use in Detecting Compact Well-Separated Clusters // *Journal of Cybernetics*. — 1973. — Vol. 3, no. 3. — Pp. 32–57. <http://dx.doi.org/10.1080/01969727308546046>.

Приложение

| | Предсказанный класс | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | | |
|-----------------|---------------------|------|------------|----------|-------|--------|----------|-------|-----------|--------|-------|------------|-----------|-------|----------|--------|----------|--------|----------|-----------|-------|----------|---------|----------|---------|--------|-----------------|--------------|--------|---------|------------|---------|
| | animals | auto | basketball | biathlon | books | boxing | business | chess | companies | cosmos | crime | cybersport | economics | films | football | forces | formula1 | hockey | internet | judiciary | music | politics | reality | religion | science | skiing | social-networks | technologies | tennis | theatre | volleyball | weapons |
| animals | 0.89 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.02 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0.02 | 0 | 0.01 | 0.02 | 0 | 0 | 0.03 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| auto | 0 | 0.87 | 0 | 0 | 0 | 0 | 0.05 | 0 | 0.02 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0.03 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 |
| basketball | 0 | 0 | 0.98 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| biathlon | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| books | 0 | 0 | 0 | 0 | 0.87 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.07 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 |
| boxing | 0 | 0 | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| business | 0 | 0.02 | 0 | 0 | 0 | 0 | 0.85 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0.02 | 0 | 0 | 0 | 0 | 0.04 | 0 | 0 | 0 | 0 |
| chess | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| companies | 0 | 0.04 | 0 | 0 | 0 | 0 | 0.12 | 0 | 0.72 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.03 | 0.01 | 0 | 0.02 | 0.01 | 0 | 0 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0.01 |
| cosmos | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.91 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.06 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0 |
| crime | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.82 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.08 | 0 | 0.07 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| cybersport | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.98 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| economics | 0 | 0.01 | 0 | 0 | 0 | 0 | 0.2 | 0 | 0 | 0 | 0 | 0 | 0.68 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.07 | 0.02 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 |
| films | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.96 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| football | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| forces | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0.01 | 0.01 | 0 | 0 | 0 | 0 | 0.76 | 0 | 0 | 0 | 0.01 | 0 | 0.08 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.12 |
| formula1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| hockey | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| internet | 0.01 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0.02 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0 | 0.73 | 0 | 0.01 | 0.03 | 0 | 0 | 0.01 | 0 | 0.08 | 0.05 | 0 | 0 | 0 | 0 |
| judiciary | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0.07 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.85 | 0 | 0.03 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| music | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.94 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 |
| politics | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.01 | 0 | 0.92 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| reality | 0 | 0.01 | 0 | 0 | 0 | 0 | 0.07 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0.87 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| religion | 0 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0.07 | 0.01 | 0.96 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| science | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.06 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0.9 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 |
| skiing | 0 | 0 | 0 | 0.03 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.96 | 0 | 0 | 0 | 0 | 0 | 0 |
| social-networks | 0.02 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0.03 | 0 | 0 | 0 | 0 | 0.15 | 0 | 0.03 | 0.04 | 0 | 0 | 0 | 0 | 0.66 | 0.01 | 0 | 0 | 0 | 0 |
| technologies | 0 | 0.01 | 0 | 0 | 0 | 0 | 0.08 | 0 | 0 | 0.05 | 0 | 0 | 0 | 0.01 | 0 | 0.01 | 0 | 0 | 0.08 | 0 | 0 | 0.01 | 0.01 | 0 | 0.04 | 0 | 0.01 | 0.67 | 0 | 0 | 0 | 0.02 |
| tennis | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.99 | 0 | 0 | 0 |
| theatre | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.09 | 0 | 0 | 0 | 0 | 0 | 0 | 0.02 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.85 | 0 | 0 |
| volleyball | 0 | 0 | 0.01 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.97 | 0 |
| weapons | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0.08 | 0 | 0 | 0 | 0 | 0 | 0.02 | 0 | 0 | 0 | 0 | 0 | 0.01 | 0 | 0 | 0 | 0.87 |

Рисунок 4 — Матрица ошибок линейного SVM

| | | | |
|---------------------------|------|------|------|
| animals (367) | 0.88 | 0.89 | 0.88 |
| auto (1036) | 0.82 | 0.86 | 0.84 |
| basketball (1344) | 0.99 | 0.98 | 0.99 |
| biathlon (670) | 0.98 | 0.99 | 0.98 |
| books (282) | 0.87 | 0.88 | 0.87 |
| boxing (754) | 0.99 | 0.99 | 0.99 |
| business (4807) | 0.85 | 0.85 | 0.85 |
| chess (142) | 0.98 | 0.99 | 0.99 |
| companies (995) | 0.88 | 0.72 | 0.79 |
| cosmos (820) | 0.77 | 0.91 | 0.84 |
| crime (1592) | 0.81 | 0.82 | 0.82 |
| cybersport (550) | 0.99 | 0.98 | 0.99 |
| economics (728) | 0.83 | 0.68 | 0.75 |
| films (1978) | 0.92 | 0.96 | 0.94 |
| football (2098) | 0.96 | 0.99 | 0.98 |
| forces (1198) | 0.80 | 0.77 | 0.78 |
| formula1 (430) | 0.96 | 1.00 | 0.98 |
| hockey (1920) | 0.99 | 0.99 | 0.99 |
| internet (1520) | 0.75 | 0.73 | 0.74 |
| judiciary (1249) | 0.80 | 0.84 | 0.82 |
| music (1143) | 0.91 | 0.94 | 0.93 |
| politics (5355) | 0.89 | 0.93 | 0.91 |
| realty (1463) | 0.87 | 0.87 | 0.87 |
| religion (271) | 0.90 | 0.86 | 0.88 |
| science (1667) | 0.89 | 0.90 | 0.90 |
| skiing (209) | 0.98 | 0.96 | 0.97 |
| social-networks (612) | 0.71 | 0.66 | 0.69 |
| technologies (2129) | 0.77 | 0.67 | 0.72 |
| tennis (1071) | 0.99 | 0.99 | 0.99 |
| theatre (265) | 0.86 | 0.84 | 0.85 |
| volleyball (158) | 1.00 | 0.97 | 0.99 |
| weapons (1236) | 0.83 | 0.87 | 0.85 |
| Precision Recall F1-score | | | |

| | | | |
|---------------------------|------|------|------|
| animals (367) | 0.88 | 0.84 | 0.86 |
| auto (1036) | 0.81 | 0.84 | 0.83 |
| basketball (1344) | 0.98 | 0.97 | 0.98 |
| biathlon (670) | 0.97 | 0.99 | 0.98 |
| books (282) | 0.82 | 0.81 | 0.81 |
| boxing (754) | 0.99 | 0.97 | 0.98 |
| business (4807) | 0.83 | 0.85 | 0.84 |
| chess (142) | 0.98 | 0.97 | 0.98 |
| companies (995) | 0.82 | 0.68 | 0.74 |
| cosmos (820) | 0.80 | 0.89 | 0.84 |
| crime (1592) | 0.80 | 0.81 | 0.81 |
| cybersport (550) | 0.99 | 0.96 | 0.97 |
| economics (728) | 0.81 | 0.68 | 0.74 |
| films (1978) | 0.92 | 0.94 | 0.93 |
| football (2098) | 0.96 | 0.98 | 0.97 |
| forces (1198) | 0.81 | 0.74 | 0.78 |
| formula1 (430) | 0.98 | 1.00 | 0.99 |
| hockey (1920) | 0.99 | 0.98 | 0.99 |
| internet (1520) | 0.72 | 0.74 | 0.73 |
| judiciary (1249) | 0.76 | 0.82 | 0.79 |
| music (1143) | 0.91 | 0.92 | 0.92 |
| politics (5355) | 0.88 | 0.92 | 0.90 |
| realty (1463) | 0.87 | 0.84 | 0.85 |
| religion (271) | 0.96 | 0.93 | 0.94 |
| science (1667) | 0.87 | 0.91 | 0.89 |
| skiing (209) | 0.96 | 0.92 | 0.94 |
| social-networks (612) | 0.66 | 0.53 | 0.59 |
| technologies (2129) | 0.77 | 0.72 | 0.75 |
| tennis (1071) | 0.99 | 0.99 | 0.99 |
| theatre (265) | 0.87 | 0.80 | 0.83 |
| volleyball (158) | 0.95 | 0.87 | 0.91 |
| weapons (1236) | 0.83 | 0.87 | 0.85 |
| Precision Recall F1-score | | | |

а) Линейный SVM

б) LightGBM + Word2Vec + bigARTM

Рисунок 5 — Precision, Recall и F1 мера по каждому из классов

| | | | | | | | | |
|-----------------|-------------------|----------------|-------------------|----------------------|----------------------|---------------|-----------------|----------------|
| animals | жить | вольер | хозяин | животный | зоопарк | питомец | кликка | животное |
| auto | авторынок | осаго | автомобильный | автопроизводитель | автопром | камаз | автоваз | автомобиль |
| basketball | рфб | евробаскет | центральной | кубок европа | баскетбол | баскетболист | евролига | нба |
| biathlon | эстафета | биатлонистка | шпиулин | сбр | хохфильцен | биатлон | ibu | биатлонист |
| books | библиотека | произведение | писательница | роман | книга | литературный | поэт | писатель |
| boxing | алоия | лебзяк | mma | посидинок | поветкин | бой | бокс | боксер |
| business | россельхознадзор | fifa | ржд | газпром | туроператор | formula | ритейлер | оао |
| chess | карякин | шахматист | карякина | магнус | шахматы | карлсен | фид | шахматный |
| companies | тысяча автомобиль | компания | миллиард кубометр | миллиард | тысяча | процент акция | ретеилер | процент |
| cosmos | космонавт | светить | прогресс | вселенная | космос | астрофизик | марс | астронавт |
| crime | грабитель | изымать | группировка | полиция | убивать | летний | преступник | тюрьма |
| cybersport | gaming | team | valve | киберфутбол | dota | киберспорт | киберспортивный | киберспортсмен |
| economics | мрот | греция | бюджет | пенсия | ввп | минфин | экономика | инфляция |
| films | мультфильм | сериал | актриса | кино | картина | режиссер | актер | фильм |
| football | поле | стадион | нападающий | матч тур | фифа | уефа | футболист | полузащитник |
| forces | развертывать | выполнение | военнослужащий | военный | шойгу | генштаб | контаненков | минобороны |
| formula1 | манор | цитировать | рено | феррари | макларен | пилот | мерседес | формула |
| hockey | авангард | ска | шайба | нападающий | хоккей | хоккеист | нхл | кхл |
| internet | википедия | сервис | ресурс | youtube | сайт | хакер | блогер | интернет |
| judiciary | стража | статья | арестовывать | колония | следственный комитет | следствие | скр | комитет россия |
| music | композиитор | евровидение | песня | певец | альбом | альбом | певица | музыкант |
| politics | лидер | кремль | парламентарий | партия | депутат | госдума | глава | мид |
| realty | объект | строительный | жилищный | строительство | жхк | ипотека | жилье | недвижимость |
| religion | монастырь | собор | церковный | муфтий | святой | христиан | митрополит | патриарх |
| science | университет | журнал | математик | физик | научный | археолог | исследователь | ученый |
| skiing | вяльбе | нортуг | лыжник | fis | легков | йохауг | лахти | устюгов |
| social-networks | некоторые | юзер | facebook | twitter | пользователь сеть | пользователь | вконтакте | соцсеть |
| technologies | vimpelcom | apple | оператор | wifi | говорить | мтс | робот | контакт |
| tennis | кубок федерация | ореп | шарапов | теннис | корт | теннисист | теннисистка | кубок дэвис |
| theatre | росгосцирк | циркового | балет | постановка | театральный | мюзикл | театр | спектакль |
| volleyball | факел | маричев | алекно | суперлига | казанский | белогорье | волейболист | волейбол |
| weapons | jane | использоваться | defense news | министерство обороны | миллиметр | миллиметровый | defense | тип |

Таблица 2: Слова с наибольшим весом по каждой теме (веса линейного SVM)

KMeans clustering

228 news processed

Перевозчик уточнил данные о жертвах сошедшего с рельсов поезда в Греции

Перевозчик уточнил данные о жертвах сошедшего с рельсов поезда в Греции

LENTA Sun 04:51 **crime**

Греческая железнодорожная компания TrainOSE уточнила данные о количестве погибших в результате крушения поезда «Афины–Салоники».

При крушении поезда в Греции погибли четыре человека

LENTA Sun 01:47 **crime**

В результате крушения поезда «Афины–Салоники» погибли четыре человека, еще пятеро ранены, сообщила греческая железнодорожная компания TrainOSE.

В Греции поезд сошел с рельсов

LENTA Sun 00:02 **crime**

На севере Греции с рельсов сошел поезд, в результате по меньшей мере 10 человек получили травмы. Об этом сообщает Reuters со ссылкой на пожарных и полицейских.

МВД Чечни не обнаружило фактов преследования геев в республике

МВД Чечни не обнаружило фактов преследования геев в республике

NOVAYA Sat 18:08 **judiciary**

Правоохранительные органы Чечни не нашли подтверждений информации о преследовании гомосексуалов в республике. Об этом сообщает Интерфакс со ссылкой на главу МВД Чечни Руслана Алханова.

ГУ МВД по Чечне обратится в суд в связи с сообщениями об убийствах геев

VEDOMOSTI Sat 16:46 **judiciary**

Глава ГУ МВД по Чечне Руслан Алханов заявил, что правоохранительные органы республики не нашли подтверждений сообщений о притеснениях геев. «Псевдосенсационное заявление о якобы задержании более 160 мужчин нетрадиционной ориентации, 50 из которых были убиты, не имеет под собой

МВД Чечни проверило информацию о притеснениях геев

LENTA Sat 16:23 **politics**

Управление МВД по Чечне проверило информацию о притеснении лиц нетрадиционной сексуальной ориентации в республике. Изложенные в материалах издания сведения не нашли подтверждения, заявил министр внутренних дел региона Руслан Алханов. Его слова приводятся на сайте ведомства.

Рисунок 6 — Пользовательский интерфейс